

EPISÓDIO 12

Gold governada versus agente solto


Compare raw, manifest e métricas contra o mesmo ground truth

Checkpoint 12 • DuckDB local • sem cloud



O agente não deve inventar as regras que o pipeline pode executar e testar.

A pergunta que guia a aula



Ao final, você consegue...

01

Fixar ground truth

02

**Comparar três
tratamentos**

03

**Medir qualidade e
custo normalizado**

Três tratamentos, uma pergunta

Tudo permanece igual, exceto a interface oferecida ao agente.


- A: schema bruto
- B: manifest e docs
- C: métricas governadas



Ground truth vem antes do LLM

O pipeline calcula as respostas esperadas sem depender do modelo.

- Pergunta fixa
- SQL conhecido
- Resultado versionado



Ground truth vem antes do LLM



Trace transforma opinião em evidência

Resposta, SQL, resultado, tokens, tools e latência ficam no mesmo JSON.


- input/output tokens
- tool calls
- joins inválidos
- custo normalizado



Trace transforma opinião em evidência


01

Pergunta




02

Trace



03

Score




04

Comparação

Fixture não é execução real

Traces gravados testam o avaliador; não provam desempenho de um LLM.

- CI sem chave
- Dados sintéticos
- Execução real posterior



Fixture não é execução real



Fixture



Validação



LLM real

A recomendação oficial favorece contexto semântico


Mais modelagem tende a ampliar precisão e segurança das respostas.

- Cobertura
- Precisão
- Confiabilidade



A recomendação oficial favorece contexto semântico


Mais modelagem tende a ampliar precisão e segurança das respostas.



A arquitetura recomendada termina no agente

Regras ficam na Gold e nas métricas; o agente consome e explica.

- Silver prepara
- Gold aplica regra
- Métrica nomeia
- MCP entrega contexto



A arquitetura recomendada termina no agente



Demonstração — execute


```
python course.py checkpoint 12
```

Copie exatamente como aparece. O launcher escolhe o ambiente correto.

Demonstração — observe


01

Perguntas fixas



02

Traces gravados



03

**Avaliador e ground
truth**

RESULTADO ESPERADO

Benchmark determinístico sem chave de LLM



Checkpoint 12 • evidência reproduzível

O mesmo recurso afeta três decisões

01

Governança:
consenso em código

—

02

FinOps: custo
normalizado

—

03

IA: consumidor, não
inventor

80%

redução de analytics reportada pela Bilt

Resultado reportado; o laboratório não generaliza o percentual.

Limitações que precisam permanecer visíveis

- Fixtures não medem qualidade real do modelo
- Tokens variam por cliente
- Semântica não elimina toda ambiguidade

RADAR

**dbt State e MCP gerenciado continuam fora da
aceitação open.**



Novidade observada $\neq$ recomendação de produção

PRÓXIMO PASSO

Mova uma regra determinística do prompt para o pipeline e teste-a.

Checkpoint 12 • roteiro completo no repositório